

Instituto de Informática
Departamento de Informática Teórica

Dados de identificação**Período Letivo:** 2026/2**Professor Responsável:** BRUNO IOCHINS GRISCI**Disciplina:** TÓPICOS ESPECIAIS EM COMPUTAÇÃO XLII**Sigla:** INF05030**Créditos:** 4**Carga Horária**

CH Teórica: 50h CH Prática: 10h Total: 60h

CH Coletiva: 50h CH Autônoma: 10h CH Individual: 0h

Carga Horária de prática Extensionista (CHE) 0h

Súmula

Assuntos relacionados a inovações tecnológicas decorrentes de pesquisas recentes, aplicações específicas, interessando a um grupo restrito ou tendo caráter de temporariedade, aspectos abordados superficialmente em disciplinas regulares.

Currículos

Currículos	Etapla Aconselhada	Natureza
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO		Eletiva
ENGENHARIA DE COMPUTAÇÃO		Eletiva

Objetivos

Desenvolver os seguintes tópicos: Transparência e Explicabilidade em sistemas de IA. Redução de dimensionalidade. Aspectos Éticos em IA. Métodos de aprendizado supervisionado. Redes Neurais. Avaliação de modelos. Conceitos de Filosofia em IA.

Capacitar o estudante a compreender os fundamentos da interpretabilidade em aprendizado de máquina, incluindo seus aspectos conceituais, filosóficos, éticos e práticos, bem como sua relevância para a transparência, a confiabilidade e o uso responsável de sistemas de inteligência artificial. Desenvolver habilidades para analisar modelos supervisionados e redes neurais sob a perspectiva da interpretabilidade, relacionando desempenho preditivo, avaliação de modelos, redução de dimensionalidade e extração de conhecimento. Habilitar o aluno a conhecer, comparar e aplicar métodos de seleção de atributos, modelos naturalmente interpretáveis e técnicas de interpretação post-hoc, tanto globais quanto locais, agnósticas ou específicas ao modelo, com ênfase em explicações aplicáveis a modelos complexos. Promover a reflexão crítica sobre limitações, riscos e boas práticas no uso de ferramentas de explicabilidade, incluindo questões de vieses, justiça, segurança, ataques adversariais e interpretabilidade mecanicista. Ao final, espera-se que o estudante seja capaz de selecionar, empregar e avaliar criticamente diferentes abordagens de interpretabilidade em problemas reais de aprendizado de máquina, de forma tecnicamente fundamentada, eticamente responsável e cientificamente rigorosa.

Conteúdo Programático

Semana: 1 a 2
Título: Introdução à Interpretabilidade.
Conteúdo: Introdução à disciplina.
Seleção de atributos e análise de dados.
Interpretabilidade e explicabilidade (shortcut learning, Clever Hans effect, Rashomon effect).
Semana: 3 a 4
Título: Métodos interpretáveis
Conteúdo: Regressão Linear.
Regressão Logística.
Modelos baseados em árvores, decision rules.
Semana: 5 a 7
Título: Interpretabilidade post-hoc

Conteúdo:	Modelos agnósticos locais (por exemplo CP, ICE, LIME, counterfactual explanations, Shapley Values, SHAP). Modelos agnósticos globais (por exemplo PDP, ALE, feature interaction, Permutation Feature Importance, LOFO, surrogate models, prototypes and criticisms).
Semana:	8 a 10
Título:	Interpretando redes neurais
Conteúdo:	Learned Features. Saliency Maps. Detecting Concepts. Ataques Adversariais. Influential Instances.
Semana:	11 a 12
Título:	Interpretabilidade mecanicista
Conteúdo:	Features, circuits, universality. Sparse Autoencoder (SAE).
Semana:	13 a 14
Título:	AI Fairness e AI Safety
Conteúdo:	AI Fairness. AI Safety. Vieses em aprendizado de máquina. Ética em IA.
Semana:	15
Título:	Apresentações dos projetos
Conteúdo:	Apresentação dos projetos avaliados desenvolvidos pelos alunos.

Metodologia
A disciplina poderá utilizar o sistema Moodle/UFRGS ou similares para distribuição de material, entrega de trabalhos, organização de grupos de discussão e acompanhamento geral da disciplina, como informado pelo professor ministrante ao início do semestre. A disciplina poderá usar ferramentas como o Moodle/UFRGS, sistemas de submissão de problemas de programação online (como online judges) ou similares para avaliações e atividades didáticas. A disciplina é apresentada em aulas teórico-práticas, em que se combina a apresentação dos conceitos e técnicas com o desenvolvimento de eventuais exercícios e discussões. Algumas das aulas podem ser realizadas em laboratórios, para a implementação e visualização dos conceitos vistos em aula. Em algumas das aulas, poderão ser feitas demonstrações de ferramentas e códigos ou exibição de vídeos ou filmes pertinentes ao conteúdo. As 60 horas previstas para atividades teóricas e práticas indicadas neste Plano de Ensino incluem 30 encontros de 100 minutos de duração (2 períodos de 50 minutos por encontro, 2 encontros por semana, durante 15 semanas), em um total de 3.000 minutos, e mais 10 horas (600 minutos) de atividades autônomas, realizadas sem contato direto com o professor, correspondentes a exercícios, trabalhos ou projetos extraclasse a serem avaliados. O professor poderá se valer de aulas presenciais e de atividades à distância (desde que nos limites previstos pela UFRGS para disciplinas presenciais e empregando ferramentas para atividades remotas), assim como do apoio de Professores Assistentes (Alunos de Pós-Graduação) em Atividades Didáticas.

Experiências de Aprendizagem
Participar de aulas expositivas dialogadas. Resolver listas de exercícios extra-classe ou implementação de trabalho ou responder questionários. Realizar leitura de material disponibilizado ou assistir a vídeos ou vídeoaulas. Implementar, apresentar e relatar projetos relacionados aos tópicos vistos em aula.

Os estudantes devem seguir as regras definidas pelo professor responsável sobre o uso de ferramentas de Inteligência Artificial (IA). As diretrizes relativas ao uso de IA podem variar entre os diferentes trabalhos e atividades práticas ou teóricas que compõem as experiências de aprendizagem e os critérios de avaliação da disciplina.

Critérios de avaliação

Estão previstas as seguintes avaliações:

- Questionário teórico (Quest)
- Atividades autônomas a serem realizadas durante o semestre (Proj)
- Avaliações em laboratório (Lab)

A nota final do aluno (NF) é composta pela soma ponderada:

$$NF = 0,2*Quest + 0,4*Proj + 0,4*Lab$$

Com base na nota final, será atribuído ao aluno um dos seguintes conceitos:

- * A - Conceito Ótimo: $9,0 \leq NF$
- * B - Conceito Bom: $7,5 \leq NF < 9,0$
- * C - Conceito Regular: $6,0 \leq NF < 7,5$
- * D - Conceito Insatisfatório: $NF < 6,0$
- * FF - Falta de Frequência (menos que 75% de presença).

O aluno estará aprovado na disciplina se obtiver conceito A, B ou C e possuir ao menos 75% de presença em aula.

Atividades de Recuperação Previstas

Está previsto um Exame de Recuperação (EXAME) a ser realizado após o fechamento da NF, versando sobre todo o conteúdo da disciplina. Após a realização do Exame, a nota do aluno será recalculada (NE) como segue:

$$NE = 0,2*NF + 0,8*EXAME$$

sendo o novo conceito atribuído sobre NE conforme acima.

Bibliografia**Básica Essencial**

Christoph Molnar. Interpretable Machine Learning: A Guide for Making Black Box Models Explainable. Munich: Christoph Molnar, 2025. ISBN 978-3-911578-03-5. Disponível em: <https://christophm.github.io/interpretable-ml-book/>

Básica

Simon J.D. Prince. Understanding Deep Learning. Cambridge, MA: The MIT Press, 2023. ISBN 9780262048644. Disponível em: <http://udlbook.com>

Complementar

Sem bibliografias acrescentadas

Outras Referências

Título	Texto
Analysis and comparison of feature selection methods toward	Barbieri, M. C., Grisci, B. I., & Dorn, M. (2024). Analysis and comparison of feature selection methods towards performance and stability. Expert Systems with Applications, 249 (Part B), 123667. [https://doi.org/10.1016/j.eswa.2024.123667]
Zoom In: An introduction to circuits	Olah, C., Cammarata, N., et al. (2020). Zoom In: An introduction to circuits. Distill, 5(3), e00024-001.

Explainable machine learning for scientific insights and d	Roscher, R. et al. (2020). "Explainable machine learning for scientific insights and discoveries." IEEE Access, 8, 42200?42216.
Methods for interpreting and understanding deep neural net	Montavon, G.; Samek, W.; Müller, K.-R. (2018). "Methods for interpreting and understanding deep neural networks." Digital Signal Processing, 73, 1?15.
On the Biology of a Large Language Model	Lindsey, J. et al. (2025). On the Biology of a Large Language Model. Acessado em 11/11/2025. Disponível em: https://transformer-circuits.pub/2025/attribution-graphs/biology.html .
Assessing feature scorer results on high-dimensional datas	Grisci, B. I.; Inostroza-Ponta, M.; Dorn, M. (2025). "Assessing feature scorer results on high-dimensional datasets with t-SNE." Neurocomputing, p. 130561.
Shortcut learning in deep neural networks	Geirhos, R. et al. (2020). "Shortcut learning in deep neural networks." Nature Machine Intelligence, 2(11), 665?673.
Unmasking Clever Hans predictors and assessing what mach	Liapuschkin, S. et al. (2019). "Unmasking Clever Hans predictors and assessing what machines really learn." Nature Communications, 10, 1096.
Why should I trust you?	Ribeiro, M. T.; Singh, S.; Guestrin, C. (2016a). "Why should I trust you?" In: Proc. SIGKDD, pp. 1135?1144.

Observações

O uso de qualquer ferramenta, recurso ou meio, incluindo o uso de ferramenta de inteligência artificial, no desempenho de tarefa ou atividade acadêmica que seja de responsabilidade do aluno, com o objetivo de práticas ilícitas, tais como fraude ou plágio, constitui uma infração disciplinar segundo o Código Disciplinar Discente da UFRGS. Além de penalidades impostas no contexto avaliativo da disciplina, o estudante estará sujeito à sanções que incluem advertência, repreensão por escrito, suspensão ou, na maior gravidade, desligamento da Universidade.

Informações sobre Direitos Autorais e de Imagem: Todos os materiais disponibilizados são exclusivamente para fins didáticos, sendo vedada a sua utilização para qualquer outra finalidade, sob as penas legais. Todos os materiais de terceiros que venham a ser utilizados devem ser referenciados, indicando a autoria, sob pena de plágio. Somente poderão ser gravadas pelos alunos as atividades síncronas propostas mediante concordância prévia dos professores e colegas, sob as penas legais. É proibido disponibilizar, por quaisquer meios digitais ou físicos, os dados, a imagem e a voz de colegas e do professor, sem autorização específica para a finalidade pretendida. Os materiais disponibilizados no ambiente virtual possuem licença de uso e distribuição específica, sendo vedada a distribuição do material cuja licença não permita ou sem a autorização prévia dos professores para o material de sua autoria.